



UNIVERSIDAD  
DE BURGOS

Sistemas Inteligentes

# Práctica 3. EM para segmentación de imágenes

Curso 2024-2025

Pedro Latorre Carmona  
Depto. Ingeniería Informática – UBU


# Índice

- Introducción. Qué es la segmentación de imágenes
- *Clustering (o agrupamiento)*
- Mixtura (mezcla) de Gaussianas

# Introducción

# Introducción - Segmentación

**TENEMOS LO QUE PODRÍAMOS CONSIDERAR COMO DOS “IMÁGENES SEGMENTADAS”**




\* Imágenes de: Mean Shift: A Robust Approach toward Feature Space Analysis, by D. Comaniciu and P. Meer <http://www.caip.rutgers.edu/~comanici/MSPAMI/msPamiResults.html>

# Introducción - Segmentación



Contorno



Etiquetas



Colores medios

# Introducción - Segmentación

Podríamos definir la segmentación de imágenes como aquel proceso en el que se divide una imagen en un conjunto **conexo** (digital) de píxeles.

Existe una definición formal de conectividad aplicada a imágenes, denominada conectividad digital. Quien quiera saber un poco más:

<http://topologiaparausuarios.es/GruposHH/GHH1-Conexidad.html>


# Introducción - Segmentación

De todas formas, existen formas más sencillas de entenderlo. Por ejemplo, teniendo en cuenta:

[https://es.wikipedia.org/wiki/Conjunto\\_conexo](https://es.wikipedia.org/wiki/Conjunto_conexo)

**A es conexo**

**B NO es conexo**



# Introducción - Segmentación

Podríamos considerar tres grandes grupos de casos:

1. Partición en regiones, las cuales terminan cubriendo toda la imagen
2. Estructuras lineales, tales como segmentos:
  - lineales
  - curvos
3. Estructuras 2D, como pueden ser:
  - círculos
  - elipses



# Introducción - Segmentación

## Criterios de segmentación:

El conjunto de regiones ( $S_i$ ) en las que se divide una segmentación deben cumplir los siguientes criterios (entendidos en forma de **operadores matemáticos**):

**FUNDAMENTAL**

1.  $\cup S_i = S$
2.  $S_i \cap S_j = \emptyset, \forall i \neq j$
3.  $\forall S_i, P(S_i) = \text{True}$
4.  $P(S_i \cap S_j) = \text{False}, S_i \neq S_j, S_i \text{ adyacente a } S_j$

$P$  es la función Predicado de homogeneidad (función matemática que define la similitud entre dos conjuntos)

## Clustering o *agrupamiento*

# Clustering

Imagina:

## CRITERIO 1: PROGENIE



## CRITERIO 2: EXISTENCIA DE PULMONES



## CRITERIO 3: MEDIO DONDE LOS ANIMALES VIVEN



# Clustering

Clustering significa “crear agrupaciones (clusters)”.


Para poder hacerlo:

- Necesitamos un **criterio**.
- Una vez se han creado los *grupos*, necesitamos una **regla de validación**.
- Por último, necesitamos **interpretar** los resultados.

# Clustering

¿Por qué necesitamos validar los resultados?

**Respuesta:** Porque a veces es posible obtener varias soluciones.




# Mixtura de Gaussianas y Método EM

# Clustering - ejemplos

## *Mixturas de Gaussianas – Expectación Maximización (EM)*

¿Qué es una **(función) Gaussiana**?



$$N(x | \mu, \sigma) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x - \mu)^2}{2\sigma^2}}$$

# Clustering - ejemplos

## *Mixturas de Gaussianas – Expectación Maximización (EM)*

¿Qué ocurre en el caso 2D?

$$N(x \mid \mu, \Sigma) = \frac{1}{(2\pi)^{d/2} \sqrt{|\Sigma|}} \exp\left(-\frac{1}{2}(x - \mu)^T \Sigma^{-1}(x - \mu)\right)$$

$$N \left[ \begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix}, \begin{pmatrix} \sigma_1^2 & \sigma_{12} \\ \sigma_{21} & \sigma_2^2 \end{pmatrix} \right]$$



# Clustering - ejemplos

## *Mixturas de Gaussianas – Expectación Maximización (EM)*

¿Qué propiedades tiene la matriz de covarianza?

$$\Sigma \equiv \begin{pmatrix} \sigma_{11}^2 & \rho_{12} \\ \rho_{21} & \sigma_{22}^2 \end{pmatrix}$$


Se puede demostrar que:  $\rho_{ij} = \rho_{ji} \Rightarrow \Sigma = \Sigma^T$

**T** representa el símbolo de **operador TRASPUESTA**.

# Clustering - ejemplos

## *Mixturas de Gaussianas – Expectación Maximización (EM)*

¿Cómo pueden ser las **matrices de covarianza**?



# Clustering - ejemplos

## *Mixturas de Gaussianas – Expectación Maximización (EM)*

¿Cómo sería en 3D?

$$\Sigma \equiv \begin{pmatrix} \sigma_{11}^2 & \rho_{12} & \rho_{13} \\ \rho_{21} & \sigma_{22}^2 & \rho_{23} \\ \rho_{31} & \rho_{32} & \sigma_{33}^2 \end{pmatrix}$$

En este caso, y en general:  $\rho_{ij} = \rho_{ji} \Rightarrow \Sigma = \Sigma^T$

# Clustering - ejemplos

## *Mixturas de Gaussianas – Expectación Maximización (EM)*

Por otro lado, se puede demostrar que:

$$\Sigma \equiv \begin{pmatrix} \sigma_{11}^2 & 0 \\ 0 & \sigma_{22}^2 \end{pmatrix} \Rightarrow \Sigma^{-1} = \begin{pmatrix} 1/\sigma_{11}^2 & 0 \\ 0 & 1/\sigma_{22}^2 \end{pmatrix}$$

Y lo mismo para 3 o más dimensiones.

# Clustering - ejemplos


## Mixturas de Gaussianas – Expectación Maximización (EM)

¿Qué es una **Mixtura de Gaussianas (MoGs)**?

$$p(x) = \sum_{j=1}^M p(\Omega_j) \cdot p(x|\Omega_j)$$

Curva envolvente—  
Combinación lineal de Gaussianas


Una Gaussiana 1D



# Clustering - ejemplos

## *Mixturas de Gaussianas – Expectación Maximización (EM)*

Si tengo un histograma:



# Clustering - ejemplos

## *Mixturas de Gaussianas – Expectación Maximización (EM)*

¿Qué es una **Mixtura de Gaussianas (MoGs)**?

$$p(x) = \sum_{j=1}^M p(\Omega_j) \cdot p(x|\Omega_j)$$



$$p(x|\Omega_j) = \frac{1}{(2\pi)^{d/2} |\Sigma_j|^{1/2}} e^{\left[ -\frac{1}{2} \left( (x-\mu_j)^T \Sigma_j^{-1} (x-\mu_j) \right) \right]}$$

$$p(\Omega_j) \equiv \text{Pesos}$$

# Clustering - ejemplos

## *Mixturas de Gaussianas – Expectación Maximización (EM)*

¿Qué tendríamos en 2D?






# Clustering - ejemplos

## *Mixturas de Gaussianas – Expectación Maximización (EM)*

En una Mixtura de Gaussianas, tenemos:

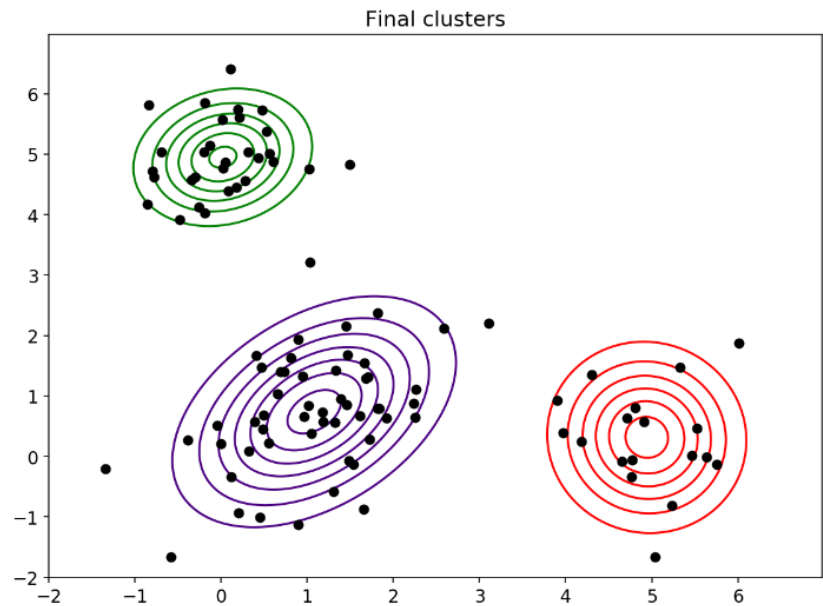

$$p(x) = \sum_{j=1}^M p(\Omega_j) \cdot p(x|\Omega_j)$$

$$p(x|\Omega_j) = \frac{1}{(2\pi)^{d/2} |\Sigma_j|^{1/2}} e^{\left[ -\frac{1}{2} \cdot (x - \mu_j)^T \Sigma_j^{-1} (x - \mu_j) \right]}$$



# Clustering - ejemplos



## *Mixturas de Gaussianas – Expectación Maximización (EM)*



# Clustering - ejemplos

## *Mixturas de Gaussianas – Expectación Maximización (EM)*


¿Podemos saber el número de grupos que sería más adecuado tener?



# Clustering - ejemplos

## *Mixturas de Gaussianas – Expectación Maximización (EM)*

¿Podemos saber el número de grupos que sería más adecuado tener, o que su distribución “permite explicar”?



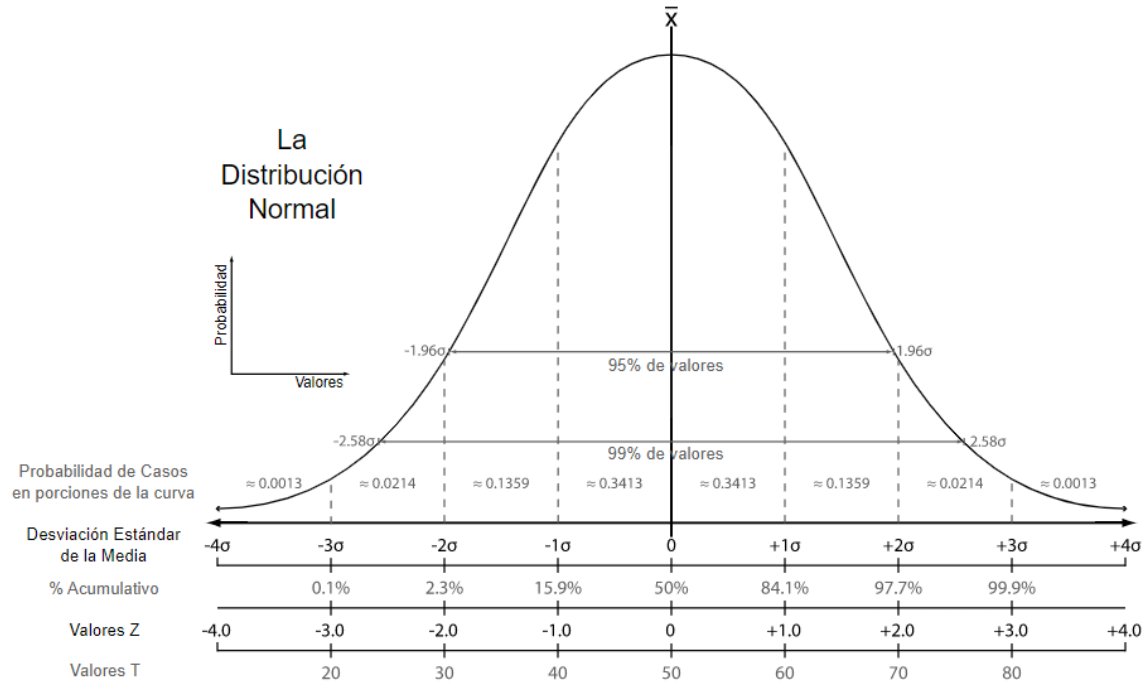
**BIC:** Bayes Information Criterion

**AIC:** Akaike Information Criterion (lo propuso el matemático/estadístico *Hirotsugu Akaike*)

# Clustering - ejemplos

## *Mixturas de Gaussianas – Expectación Maximización (EM)*


¿Qué es esa especie de “curvas de nivel que se representa?”



# Clustering - ejemplos

## *Mixturas de Gaussianas – Expectación Maximización (EM)*

¿Qué es esa especie de “curvas de nivel” que se representa?



# Clustering - ejemplos

## *Mixturas de Gaussianas – Expectación Maximización (EM)*

El algoritmo de mixturas de Gaussianas funciona utilizando la **REGLA DE BAYES**

**¿Por qué?**

Porque nos da un marco perfecto para “introducir información adicional”.

Veamos qué es esto.

# Clustering - ejemplos

## *Mixturas de Gaussianas – Expectación Maximización (EM)*

Imaginémonos la siguiente situación:

*Un colegio está formado por un 60% de chicos y un 40% de chicas. Elegimos aleatoriamente un estudiante.*

*¿Cuál es la probabilidad que sea un chico?*

*Respuesta:  $p(\text{Chico}) \equiv p(\omega_1) = 0.6$*



# Clustering - ejemplos

## *Mixturas de Gaussianas. Expectación - Maximización (EM)*

Imaginémonos ahora:



*Partamos del caso anterior. Se nos proporciona información adicional. Nos dicen que en este colegio, todos los chicos (100%) llevan pantalones y el 50% de las chicas, también.*

*Si una cámara observa un estudiante, con esta información adicional, ¿qué podemos decir sobre la probabilidad de que sea chico? ¿Cambiará el valor de **0.6**?*

# Clustering - ejemplos

## *Mixturas de Gaussianas. Expectación - Maximización (EM)*

$$p(\text{Chico}|\text{Pantalones}) \equiv p(\omega_1|x)$$

$$p(\omega_1|x) = \frac{p(x|\omega_1) \cdot p(\omega_1)}{p(x)} = \frac{p(x|\omega_1) \cdot p(\omega_1)}{p(x|\omega_1) \cdot p(\omega_1) + p(x|\omega_2) \cdot p(\omega_2)} = \frac{1 \cdot 0.6}{1 \cdot 0.6 + 0.5 \cdot 0.4} = \mathbf{0.75}$$

### REGLA DE BAYES

$$P(A | B) = \frac{P(B | A)P(A)}{P(B)}$$

# Clustering - ejemplos

## *Mixturas de Gaussianas. Expectación - Maximización (EM)*

*¿Qué ha ocurrido?*

*Que nuestra probabilidad de acierto sobre la elección de chico/chica ha cambiado:*

**0.6 → 0.75**

*Por el hecho de tener información adicional sobre el tanto por ciento de personas que llevan pantalones, dependiendo del género.*

Y, para este colegio en concreto, **0.75 debería ser una mejor estimación que 0.6**

# Clustering - ejemplos

*Mixturas de Gaussianas. Expectación - Maximización (EM)*

**APLIQUEMOS AHORA LA REGLA DE BAYES AL CASO QUE NOS OCUPA**

# Clustering - ejemplos

## *Mixturas de Gaussianas – Expectación Maximización (EM)*

Aplicando la Regla de Bayes, y:

$$p(x) = \sum_{j=1}^M p(\Omega_j) \cdot p(x|\Omega_j); \quad p(x|\Omega_j) = \frac{1}{(2\pi)^{d/2} |\Sigma_j|^{1/2}} e^{\left[-\frac{1}{2} \cdot \left((x-\mu_j)^T \Sigma_j^{-1} (x-\mu_j)\right)\right]}$$

tenemos:

$$p(\Omega_j|x) = \frac{p(\Omega_j) \cdot p(x|\Omega_j)}{\sum_{k=1}^M p(\Omega_k) \cdot p(x|\Omega_k)}$$

# Clustering - ejemplos

## Mixturas de Gaussianas – Expectación Maximización (EM)

Expectación (E):

$$p(\Omega_j | x_i)^{(t)} = \frac{p(\Omega_j)^{(t)} \cdot p(x_i | \Omega_j)^{(t)}}{\sum_k p(\Omega_k)^{(t)} \cdot p(x_i | \Omega_k)^{(t)}}$$

Maximización (M):

$$p(\Omega_j)^{(t+1)} = \frac{1}{n} \sum_{i=1}^n \left\{ p(\Omega_j | x_i)^{(t)} \right\}$$

$$\mu_j^{(t+1)} = \frac{\sum_{i=1}^n \left\{ x_i p(\Omega_j | x_i)^{(t)} \right\}}{\sum_{i=1}^n \left\{ p(\Omega_j | x_i)^{(t)} \right\}}$$

$$\Sigma_j^{(t+1)} = \frac{\sum_{i=1}^n \left\{ p(\Omega_j | x_i)^{(t)} \right\} (x_i - \mu_j^{(t+1)}) (x_i - \mu_j^{(t+1)})^T}{\sum_{i=1}^n \left\{ p(\Omega_j | x_i)^{(t)} \right\}}$$

# Clustering - ejemplos


## *Mixturas de Gaussianas – Expectación Maximización (EM)*

$k = 1$

$k = 2$

$k = 5$

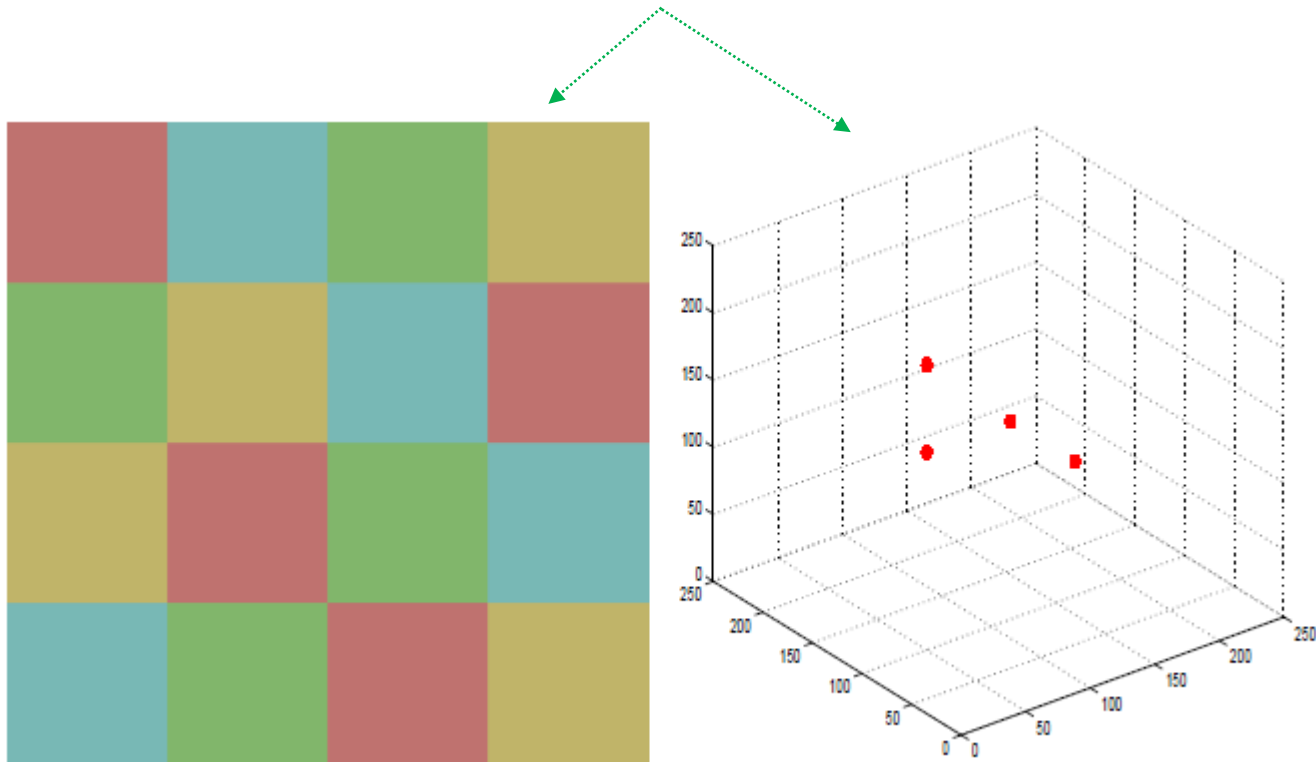
$k = 20$



# Clustering - ejemplos

## *Mixturas de Gaussianas – Expectación Maximización (EM)*

Partimos de una imagen sin ruido







# Clustering - ejemplos



## *Mixturas de Gaussianas – Expectación Maximización (EM)*

Introducimos “ruido Gausiano”



# Clustering - ejemplos



*Mixturas de Gaussianas – Expectación Maximización (EM)*



# Medidas de evaluación de la calidad de la segmentación

# Medidas de evaluación

Para poder evaluar la calidad de la segmentación de/en una imagen, necesitamos crear la llamada imagen “**GROUNDTRUTH**”, o verdadera.



A veces ocurre que la segmentación manual NO es lo suficientemente precisa

# Medidas de evaluación

Cuando tenemos una imagen formada por dos tipos de objetos, se puede definir:

- **TP: “True Positives”** → Número de píxeles que son de un grupo (se elige uno de los dos) en la imagen segmentada, y del mismo grupo en la imagen “groundtruth”.
- **TN: “True Negatives”** → Número de píxeles que son del otro grupo en la imagen segmentada, y de ese mismo grupo en la imagen “groundtruth”.
- **FP: “False Positives”** → Píxeles definidos por el método de segmentación como del grupo primero, siendo en realidad del segundo
- **FN: “False Negatives”** → Píxeles definidos por el método de segmentación como del segundo grupo, siendo del primero.

# Medidas de evaluación

A partir de aquí, podemos definir:

- Sensibilidad =  $\frac{TP}{TP+FN} \cdot 100$
- Especificidad =  $\frac{TN}{TN+FP} \cdot 100$
- Precisión global =  $\frac{TP+TN}{TP+TN+FP+FN} \cdot 100$

# Medidas de evaluación

En el caso de **más de dos (tipos de) objetos**, tenemos:

$$\text{Precisión global} = \frac{NTCC}{NTCC + NTCl} \cdot 100$$

donde:

- NTCC: Número total de clasificaciones correctas
- NTCl: Número total de clasificaciones incorrectas

# Referencias

- [1] David A. Forsyth, Jean Ponce, Computer Vision: A Modern Approach, Prentice Hall, 2003.
- [2] Christopher Bishop, Pattern Recognition and Machine Learning, Information Science and Statistics Series, Springer Verlag, 2006.
- [3] Sergios Theodoridis, Konstantinos koutroumbas, Pattern Recognition, Academic press, 2009.
- [4] Frank Höppner, Frank Klawonn, Rudolf Kruse, Thoms Runkler, Fuzzy Cluster Analysis, John Wiley & Sons, 2000.